



La Información Mutua como herramienta para cuantificar el grado de dependencia y la reducción de incertidumbre entre variables aleatorias

Juan Luis Aguayo Lazcano
Profesor patrocinante: Dr. Víctor Poblete R.
Magister en Acústica y Vibraciones

January 15, 2026

- ① Motivación
- ② Introducción
- ③ Marco Teórico

La información mutua proporciona una medida cuantitativa de la relación entre dos variables, permitiéndonos evaluar la cantidad de información compartida entre ellas. Al cuantificar esta información compartida, podemos obtener información valiosa sobre las dependencias y patrones que existen dentro de nuestros datos.

La información mutua (MI, por sus siglas en inglés) es un concepto fundamental de la teoría de la información que cuantifica la cantidad de información que dos variables aleatorias o randómicas proporcionan una sobre la otra. Mide la reducción de incertidumbre de una variable debido al conocimiento de la otra [1].

La MI se utiliza ampliamente para cuantificar dependencias entre variables aleatorias y tiene aplicaciones importantes en selección de características, clustering, clasificación, teoría de comunicaciones y muchas otras áreas dentro de la informática.[4]

En el ámbito de la teoría de la información, la entropía también denominada entropía de la información o entropía de Shannon, es una medida de la incertidumbre o la aleatoriedad de una fuente de datos, cuantificando la cantidad promedio de información que contiene o libera un mensaje, esto es, a mayor entropía, mayor será la imprevisibilidad del mensaje.

El contenido de información de Shannon $h(x)$ cuantifica el grado de sorpresa asociado a observar el resultado x , matemáticamente

$$h(x) = \log p(x),$$

donde la base del logaritmo fija la unidad de medida, esto es,
base 2: bits,
base e : nats,
base 10: hartleys o bans.

En palabras simples tenemos,

Si $p(x)$ es grande (evento frecuente), entonces $h(x)$ es pequeño, luego el resultado aporta poca información nueva.

Si $p(x)$ es pequeño (evento infrecuente o raro), entonces $h(x)$ es grande, luego el resultado es altamente informativo. Por lo tanto, esto refleja

directamente la idea de sorpresa: cuanto más raro es un evento, mayor es su contenido informativo.

Veamos el siguiente ejemplo, considérese una variable aleatoria discreta X que puede tomar tres valores $X \in \{a, b, c\}$ con la siguiente distribución de probabilidad:

$$p(a) = 0.5, \quad p(b) = 0.25, \quad p(c) = 0.25.$$

Usaremos logaritmos en base 2, por lo que la información se mide en bits.

Si $x = a$, entonces $h(a) = \log_2 0.5 = 1 \text{ bit}$. Si $x = a$, entonces

$h(a) = \log_2 0.25 = 2 \text{ bit}$. Si $x = a$, entonces $h(a) = \log_2 0.25 = 2 \text{ bit}$. En

este ejemplo, los resultados menos probables presentan un mayor contenido de información que el resultado más probable.

Matemáticamente, la entropía de un mensaje X , denotado por $H(X)$, es el valor medio ponderado de la cantidad de información de los diversos estados del mensaje:

$$H(X) = - \sum_i p(x_i) \log_2 p(x_i) = \sum_i p(x_i) \log_2 \frac{1}{p(x_i)}$$

que representa una medida de la incertidumbre media acerca de una variable aleatoria y por lo tanto de la cantidad de información.

El sistema de alertas meteorológicas de una ciudad utiliza 4 tipos de alertas codificadas en colores: VERDE (Condiciones normales), AMARILLO (Precaución), NARANJA (Alerta) y ROJO (Emergencia) Según datos históricos de 1000 días, las probabilidades de cada alerta son:

ALERTA	DIAS	PROBABILIDAD
Verde	650	$p(v)=0.65$
Amarillo	250	$p(a)=0.25$
Naranja	80	$p(n)=0.08$
Rojo	20	$p(r)=0.02$

observación: El sistema transmite las alertas usando un **código binario**. Calcular la entropía $H(X)$ del sistema de alertas (en bits).

$$H(X) = p(v) \log \frac{1}{p(v)} + p(a) \log \frac{1}{p(a)} + p(n) \log \frac{1}{p(n)} + p(r) \log \frac{1}{p(r)}$$

$$H(X) = 0.65 \log_2 \frac{1}{0.65} + 0.25 \log_2 \frac{1}{0.25} + 0.08 \log_2 \frac{1}{0.08} + 0.02 \log_2 \frac{1}{0.02}$$

$$H(X) = 1.3084 \text{ bits}$$

El valor obtenido representa la incertidumbre promedio del sistema de alertas, dado que Verde es altamente probable, la entropía es menor que la entropía máxima posible para 4 símbolos, esto es

$$H_{\text{máx}} = \log_2(4) = 2 \text{ bits}.$$

Este resultado indica que el sistema no es equiprobable, y por tanto puede codificarse eficientemente usando un código binario optimizado.

La **entropía condicional** supone que en vez de tener una variable aleatoria X , existe otra variable Y independientes entre sí, es decir el conocimiento de una (por ejemplo, Y) entrega información sobre la otra (por ejemplo, X). Desde el punto de vista de la entropía de la información podemos decir que la información de Y disminuirá la incertidumbre de X . Por lo tanto, podemos decir que la entropía será condicional a Y , y por tanto:

$$H(X, Y) = - \sum_{x,y} p(x, y) \log_2 p(x, y) = \sum_{x,y} p(x, y) \log_2 \frac{1}{p(x, y)}$$

Analicemos el siguiente ejemplo, considérese una fuente de información que emite dos símbolos binarios X e Y , que pueden tomar los valores

$$X \in \{0,1\}, \quad Y \in \{0,1\}$$

.

La distribución de probabilidad conjunta está dada por la siguiente tabla:

X	Y	P(X,Y)
0	0	0.4
0	1	0.1
1	0	0.2
1	1	0.3

Es inmediato verificar que:

$$\sum_{xy} P(X,Y) = 1.$$

Aplicamos directamente la definición término a término.

$$H(X, Y) = 0.40 \log_2 \left(\frac{1}{0.40} \right) + 0.10 \log_2 \left(\frac{1}{0.10} \right) + 0.20 \log_2 \left(\frac{1}{0.20} \right) + 0.30 \log_2 \left(\frac{1}{0.30} \right)$$

$H(X, Y) \approx (0.529 + 0.332 + 0.464 + 0.521) \approx 1.846 \text{ bits}$. En este

ejemplo, observar simultáneamente X e Y genera, en promedio, 1.85 bits de información por símbolo conjunto. Este valor es menor que el

máximo para 2 bits, lo que indica cierta estructura o dependencia estadística entre X e Y .

Por el Teorema de Bayes tenemos que $p(x, y) = p(y)p(y|x)$ donde $p(x|y)$ es la probabilidad de que se dé un estado X conocida Y , podemos decir:

$$H(X|Y) = \sum_y p(y) \sum_x p(x|y) \log_2 \frac{1}{p(x|y)}$$

En terminos de entropía, la información mutua puede expresarse como

$$H(X, Y) = H(X) - H(X|Y) = H(Y) - H(X|Y)$$

donde $H(X)$ y $H(Y)$ denotan las entropías de X e Y , y $H(X, Y)$ es su entropía conjunta. [3][7][8]

La entropía condicional cuantifica la cantidad de información necesaria para describir el resultado de una variable aleatoria X dado que el valor de otra variable aleatoria Y es conocido. Aquí, la información se mide en shannons, nats, o hartleys.

Sea (X, Y) un par de variables aleatorias discretas con distribución conjunta $p(x, y)$, la entropía condicional de X dado Y es el promedio, sobre y , de la entropía condicional de X dado y , esto es,

$$\begin{aligned} H(X|Y) &\equiv \sum_{y \in \mathcal{A}_Y} p(y) \left[\sum_{x \in \mathcal{A}_X} p(x|y) \log \frac{1}{p(x|y)} \right] \\ &= \sum_{xy \in \mathcal{A}_X \mathcal{A}_Y} p(x, y) \log \frac{1}{p(x|y)}. \end{aligned}$$

Calculemos la entropía condicional $H(X|Y)$ de un sistema de monitoreo clasifica el estado del clima de una ciudad mediante la variable aleatoria

$$X \in \{Soleado, Lluvioso\},$$

y registra simultáneamente si se produce o no un congestión vehicular, modelado por la variable

$$Y \in \{Sí, No\}.$$

La distribución de probabilidad conjunta $P(X, Y)$ es la siguiente:

Clima X	Congestión Y	P(X,Y)
Soleado	No	0.5
Soleado	Si	0.1
Lluvioso	No	0.1
Lluvioso	Si	0.3

Para calcular la entropía condicional $H(X|Y)$ debemos primero calcular las probabilidades marginales $P(Y)$, por lo que se obtiene:

$$P(\text{congestión} : Y = \text{No}) = 0.10 + 0.30 = 0.40$$

$$P(\text{congestión} : Y = \text{Sí}) = 0.50 + 0.10 = 0.60$$

Ahora, calculamos las probabilidades conjuntas $P(X, Y)$, esto es:

$$P(X : \text{soleado}, Y = \text{No}) = 0.5$$

$$P(X : \text{soleado}, Y = \text{Sí}) = 0.1$$

$$P(X : \text{lluvioso}, Y = \text{No}) = 0.1$$

$$P(X : \text{lluvioso}, Y = \text{Sí}) = 0.3$$

Finalmente, aplicando una de las fórmulas para calcular la entropía condicional

$$H(X|Y) = \sum_{xy} P(X, Y) \log_2 \left(\frac{P(Y)}{P(X, Y)} \right)$$

obtenemos:

$$\begin{aligned} H(X|Y) &= 0.5 * \log_2 \left(\frac{0.6}{0.5} \right) + 0.1 * \log_2 \left(\frac{0.4}{0.1} \right) + 0.1 * \log_2 \left(\frac{0.6}{0.1} \right) + \\ &0.3 * \log_2 \left(\frac{0.4}{0.3} \right) \approx 0.13152 + 0.2 + 0.2585 + 0.12451; \text{bits} \\ H(X|Y) &\approx 0.71453 \text{ bits} \end{aligned}$$

De forma análoga, calculamos $H(Y|X)$ y se obtiene $H(Y|X) \approx 0.71453$ bits.

[Observación: la igualdad en las entropías no es general, sino consecuencia de la simetría numérica de las probabilidades marginales y condicionales.]

Por lo tanto, conocer si hay congestión $H(X|Y)$ reduce la incertidumbre sobre el clima en aproximadamente 0.71 bits. Del mismo modo, conocer el clima $H(Y|X)$ reduce la incertidumbre sobre la congestión en la misma magnitud. Por lo tanto, ambas variables están correlacionadas, pero ninguna determina completamente a la otra.

En teoría de la información, la información mutua mide la cantidad de información que dos variables aleatorias comparten. Equivalentemente, cuantifica la reducción de incertidumbre en una variable al conocer la otra.

En palabras simples, la información mutua es capaz de responder ¿Cuánto se reduce la incertidumbre sobre X cuando se conoce Y ?, en particular:

- Si conocer Y no aporta nada sobre X , la información mutua es cero.
- Si conocer Y determina completamente a X , la información mutua es máxima.

Para definir la información mutua, sean X y Y variables aleatorias discretas con distribución conjunta $p(x, y)$ y sus distribuciones marginales son $p(x)$, $p(y)$. Matemáticamente, nos queda

$$I(X; Y) = \sum_{xy \in \mathcal{A}_X \mathcal{A}_Y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}$$

Esta expresión compara la distribución conjunta real con la que existiría si X e Y fueran independientes.

Si trabajamos con el ejemplo anterior, calculemos la información mutua $I(X;Y)$ del sistema de monitoreo.

Para las probabilidades marginales $P(Y)$ y $P(X)$ tenemos,

$$P(\text{congestión} : Y = \text{No}) = 0.60 \quad P(\text{soleado}) = 0.6$$

$$P(\text{congestión} : Y = \text{Sí}) = 0.40 \quad P(\text{lluvioso}) = 0.4$$

Para las probabilidades conjuntas $P(X,Y)$ nos queda,

$$P(X : \text{soleado}, Y = \text{No}) = 0.5 \quad P(X : \text{lluvioso}, Y = \text{No}) = 0.1$$

$$P(X : \text{soleado}, Y = \text{Sí}) = 0.1 \quad P(X : \text{lluvioso}, Y = \text{Sí}) = 0.3$$

Y finalmente, las entropías condicionales son

$$H(X|Y) = H(Y|X) \approx 0.71453 \text{ bits}$$

Con esta información, podemos calcular $I(X; Y)$, usando la fórmula dada por

$$I(X; Y) = \sum_{xy \in \mathcal{A}_X \mathcal{A}_Y} p(x, y) \log \frac{p(x, y)}{p(x)p(y)}.$$

$$\begin{aligned} I(X; Y) &= 0.1 \log_2 \left(\frac{0.1}{0.6 \cdot 0.4} \right) + 0.5 \log_2 \left(\frac{0.5}{0.6 \cdot 0.6} \right) + \\ &0.3 \log_2 \left(\frac{0.3}{0.4 \cdot 0.4} \right) + 0.1 \log_2 \left(\frac{0.1}{0.4 \cdot 0.6} \right) \approx \\ &-0.1263 + 0.23697 + 0.27027 - 0.1263; I(X; Y) \approx 0.25643 \end{aligned}$$

Primero podemos concluir es que el clima y la congestión vehicular no son independientes ya que $I(X;Y) > 0$, además conocer el clima reduce la incertidumbre sobre la congestión en aproximadamente 0.26 bits.

Sin embargo, la dependencia es parcial, no determinista: aún existe incertidumbre significativa. Finalmente, el sistema de monitoreo obtiene información útil pero limitada al observar una sola de las variables.

Ahora bien, trabajemos otro ejemplo en el cual tenemos mas variables aleatorias y podemos inferir algunas interpretaciones al comparar mas de un valor de información mutua.

Sea X una variable aleatoria binaria que representa la condición de vejez ($X = 1 : SI$ o $X = 0 : NO$) y sea Y una variable aleatoria que indica la presencia de hipertensión ($Y = 1 : SI$ o $Y = 0 : NO$). Para ello se presenta la siguiente tabla:

Condición	caso 1	caso 2	caso 3	caso 4	caso 5	caso 6
Vejez	No	Si	Si	Si	Si	Si
Hipertensión	No	No	Si	No	No	No

De forma análoga al ejemplo anterior, calcularemos las entropías $H(X)$ y $H(Y)$, la entropía conjunta $H(X, Y)$, las entropías condicionales $H(X|Y)$ y $H(Y|X)$ y finalmente la información mutua $I(X; Y)$. Estos resultados son:

$$H(X) \approx 0.65 \text{ bits}, \quad H(Y) \approx 0.9183 \text{ bits}, \quad H(X, Y) \approx 1.4591 \text{ bits},$$

$$H(X|Y) \approx 0.5408 \text{ bits}, \quad H(Y|X) \approx 0.8091 \text{ bits}, \quad I(X; Y) \approx 0.1092 \text{ bits}.$$

Lo primero que se observa es que la información mutua es positiva, por lo que vejez e hipertensión no son independientes. Sin embargo $I(X; Y) \approx 0.109 \text{ bits}$ es pequeña, indicando una dependencia débil en esta muestra. En conclusión, conocer si una persona es vieja reduce solo ligeramente la incertidumbre sobre la hipertensión.

Observación: La diferencia entre $H(X|Y)$ y $H(Y|X)$ refleja que **la vejez es más predecible a partir de la hipertensión que a la inversa**, dado el fuerte sesgo de la muestra hacia $X = 1$.

Ahora bien, si cambiamos X que es una variable aleatoria binaria que daba la condición de vejez por otra variable aleatoria binaria X que da la condición de sobrepeso la cual nos entrega la siguiente tabla:

Condición	caso 1	caso 2	caso 3	caso 4	caso 5	caso 6
Sobrepeso	No	No	Si	No	Si	No
Hipertensión	No	No	Si	No	Si	No

De forma análoga, calcularemos las entropías $H(X)$ y $H(Y)$, la entropía conjunta $H(X, Y)$, las entropías condicionales $H(X|Y)$ y $H(Y|X)$ y finalmente la información mutua $I(X; Y)$ dando los siguientes resultados:

$$H(X) \approx 0.918 \text{ bits}, \quad H(Y) \approx 0.918 \text{ bits}, \quad H(X, Y) \approx 0.918 \text{ bits}$$

$$H(X|Y) = 0 \text{ bits}, \quad H(Y|X) = 0 \text{ bits}, \quad I(X; Y) \approx 0.918 \text{ bits}.$$

En este caso, existe una **dependencia perfecta** entre sobrepeso e hipertensión en esta muestra. Conocer si una persona tiene sobrepeso **determina completamente** si tiene hipertensión, y viceversa.

La entropía condicional nula indica **ausencia total de incertidumbre residual**. Como $I(X;Y) = H(X) = H(Y)$ esto significa que toda la incertidumbre de cada variable es compartida y desde el punto de vista informacional, el sistema se comporta como si ambas variables fueran la misma fuente.

Por lo tanto, al comparar los dos resultados de la información mutua $I(\text{vejez}, \text{hipertensión}) \approx 0.109 \text{ bits}$ y $I(\text{sobrepeso}, \text{hipertensión}) \approx 0.918 \text{ bits}$ se puede concluir que la relación sobrepeso–hipertensión contiene significativamente mas información compartida que la relacion vejez–hipertensión.

Esto significa que, en términos de reducción de incertidumbre, el sobrepeso es un predictor informacional mucho más fuerte de la hipertensión que la vejez.

Muchas gracias

Referencias Bibliográficas I



Alon Orlitsky, *Information Theory*, Encyclopedia of Physical Science and Technology, (2003), 751-769.



Christopher A. Sims, *Rational Inattention and Monetary Economics*, Handbook of Monetary Economics, (2010), 155-181.



Mousavian Z., Kavousi K., Masoudi-Nejad A., *Information theory in systems biology. Part I: Gene regulatory and metabolic networks*, Seminars in Cell & Developmental Biology, (2016), 3-13.



Isuwa J., Abdullahi M., Ali Y.S., Hassan I.H., Buba J.R., Aliyu I., Kim J., Oyelade O.N., *Optimizing microarray cancer gene selection using swarm intelligence: Recent developments and an exploratory study*, Egyptian Informatics Journal, (2023), 100416

Referencias Bibliográficas II

-  Barbieri M.C., Grisci B.I., Dorn M., *Analysis and comparison of feature selection methods towards performance and stability*, Expert Systems with Applications, (2024), 123667.
-  Serra A., Tagliaferri R., *Unsupervised learning: Clustering*, Encyclopedia of Bioinformatics and Computational Biology, (2018), 350-357.
-  Husheng Li, *Basics of communications*, Communications for Control in Cyber Physical Systems, (2016), 9-30.
-  Judea Pearl, *Decision and control*, Probabilistic Reasoning in Intelligent Systems, (1988), 289-331.
-  Gibson E., Futrell R., Piandadosi S.T., Dautriche I., Mahowald K., Bergen L., Levy R., *How Efficiency Shapes Human Language*, Trends in Cognitive Sciences, (2019), 389-407.



Facultad de Ciencias
de la Ingeniería
Instituto de Acústica



AuMiLab